

Trabalho prático nº 1

Extração de Conhecimento de Dados Biológicos

2025/2026

O trabalho consta da análise de um conjunto de dados usando o **programa R** e os **packages do Bioconductor**.

Os dados a analisar deverão ser provenientes de um conjunto de dados de expressão genética. Sugere-se o uso de um conjunto de dados:

- do GDC (https://portal.gdc.cancer.gov/analysis_page?app=Projects).
 - do cbiportal (<https://www.cbiportal.org/datasets>),
 - da base de dados Gene Expression Omnibus (GEO) ou ArrayExpress.
- desde que tenha **dados de expressão para pelo menos 300 amostras**.

Deverá **desenvolver scripts em R/ Bioconductor** para **carregar os dados, pré-processá-los/ fazer a sua filtragem** (se necessário) e **fazer o conjunto de análises** que lhe pareçam apropriadas.

O trabalho irá ser realizado em 3 fases a realizar até prazos distintos.

A **primeira fase** deverá ser terminada até ao dia **2 de abril** e deverá incluir:

- **explicação dos dados, sua origem e relevância**
- tarefas de **preparação e de pré-processamento** dos dados
- **sumarização dos dados** (estatística descritiva, exploração com recurso a gráficos)
- **análise estatística univariada**; análise de expressão diferencial e de enriquecimento

A **segunda fase** deverá estar concluída até **16 de abril** e deverá incluir:

- **clustering de genes** e/ou amostras
- **redução de dimensionalidade**, MDS ou outras análises não supervisionadas

A **segunda fase** deverá estar concluída até **30 de abril** e deverá incluir:

- **análise preditiva/ aprendizagem máquina** (e.g. classificação de amostras, regressão), comparando o desempenho de pelo menos dois modelos
- **seleção/ importância de genes**

Os trabalhos terão uma defesa que será realizada em conjunto com o trabalho prático 2.

Nas análises supervisionadas deverá ter em conta a existência de metadados (dados clínicos, fenotípicos ou outros) nos conjuntos de dados, escolhendo as variáveis que lhe parecerem de maior interesse para a análise.

Alguns conjuntos de dados contêm ainda diversos tipos de outros dados ómicos. Não é obrigatória a sua inclusão em qualquer tipo de análise, mas os grupos poderão opcionalmente usar alguns desses dados para análises que possam complementares a análise dos dados de expressão.

A apresentação dos resultados deverá incluir:

- apresentação do pipeline de análise e ferramentas usadas
- apresentação dos principais resultados obtidos
- discussão (podendo relacionar-se com a publicação de onde os dados originaram)

Para a realização do trabalho deverá criar um repositório no github. Até ao dia **10 de março** deverão indicar no google sheet da turma o seguinte:

- o conjunto de dados selecionado
- o URL do repositório onde irão colocar os ficheiros do trabalho; este deverá ser organizado devidamente e esta organização deve ser clara na página de entrada.

Link: (sheet ECDB)

https://docs.google.com/spreadsheets/d/1wBI3UHdxt6s_YooM8ciIDdfDN19OXXK6Q7QoNF12hEDI/edit?usp=sharing

Cada grupo deverá ter disponível até à data indicada, em cada etapa, no repositório indicado, o relatório em formato HTML e ainda um ficheiro com os comandos R (extensão R ou Rmd) que realizou de forma a que a análise se possa reproduzir. Para a geração do relatório deverá usar o *R markdown* que lhe permite incluir os comandos em R utilizados e mostrar os respetivos resultados, introduzindo texto para a descrição e discussão dos resultados. Como sugestão, sugere-se o uso do programa Rstudio que inclui as funcionalidades necessárias para a utilização do *R markdown*.